



Documentation technique et produit


SaaS B2B de devis TCE assiste par IA

Version 2 · 17 aout 2026

FastAPI · React · Supabase · Ollama · Hermes Agent

1. Presentation


Blueseatra est une plateforme multi-tenant pour les PME du batiment, du TCE et de la maintenance. Chaque entreprise dispose d'un espace isole: utilisateurs, catalogue, demandes et devis. Le produit lit une demande brute (email, PDF, photo, texte) et prepare un brouillon de devis sur **vos** prix de catalogue. L'IA n'invente pas de tarif. Vous validez avant envoi.



Bureau type: le brouillon est pret, le dernier mot reste humain.

2. Parcours devis

Parcours devis



Les prix, la TVA et la marge restent dans FastAPI. L'IA ne signe pas.


Collecter, lire, rapprocher, controler, editer, PDF. Les calculs (HT, TVA 20/10/5,5/0, marge interne) restent dans FastAPI. Hermes et Ollama ne signent pas.

3. Fonctionnalites

- Auth JWT, roles owner / admin / operator / viewer / billing_admin, isolation par tenant_id.
- Extraction IA multilingue (PDF, image, texte). Modele léger qwen2.5:7b / qwen2.5vl:7b (vision).
- Decomposition materiaux (ballon ECS, accessoires, etc.) au lieu de recopier le titre.
- Rapprochement catalogue avec score et motif. Recalcul si le catalogue change.
- Lots et sous-lots TCE, heures de main-d'oeuvre, jours de déplacement, equipe.
- Editeur: lignes typees, TVA par ligne, marge masquee sur le PDF client, ajout depuis le catalogue.
- PDF Pro Forma (SIRET, assurance, validite, acceptation).

- Journal d'audit, membres, i18n FR/EN, landing produit, identite visuelle (logo lockup).
- MCP lecture seule (demandes, devis, catalogue) pour l'agent Perplexity.

4. Architecture v2




Le frontend vit sur Hostinger (build React manuel). L'API FastAPI tourne sur Render (Francfort). Postgres est sur Supabase (UE). L'IA locale est sur un VPS OVH Ubuntu 24.04 (8 vCPU, 24 Go RAM, 200 Go NVMe, IP 162.19.44.2) avec Ollama, Hermes Agent, n8n et Caddy.¹

Couche	Ou	Role
React + Tailwind	Hostinger / blueseatra.com	UI, landing, editeur
FastAPI	Render / blueseatra-api.onrender.com	Metier, prix, PDF, auth
PostgreSQL	Supabase eu-west-1	schema blueseatra
Ollama	ia.blueseatra.com	Inference locale /api/chat
Hermes	hermes.blueseatra.com	Gateway /v1/chat/completions
n8n	n8n.blueseatra.com	Ingestion omnicanale (cible)

Caddy termine le TLS et exige X-API-Key. Les ports 11434 et 8642 ne sont pas publies. API_SERVER_HOST=0.0.0.0 uniquement sur le reseau Docker.²

5. Routage IA



Role	Modele	Chemin
Extraction	qwen2.5:7b (texte) / qwen2.5vl:7b (fichier, vision)	FastAPI → Ollama /api/chat
Raisonnement materiaux	gpt-oss:20b, think gradue low/medium/high (default medium)	FastAPI → Ollama /api/chat direct
Repli raisonnement	hermes3 (sans raisonnement natif, seul repli fonctionnel restant)	Ollama
Prix / TVA / marge	deterministe	FastAPI uniquement

Mise a jour du 23 aout 2026 (63 Go liberes) : gemma4:26b, qwen3.6:27b, qwen3:14b, deepseek-r1:14b, qwen2.5:14b et Phi-4-reasoning-vision-15B ont ete supprimees du VPS. gpt-oss:20b (deja installe, 13 Go, 20,9B parametres, quantification MXFP4) reprend le role de raisonnement materiaux : seul modele restant avec capacite «thinking» confirmee (`ollama show gpt-oss:20b`), mais ne peut pas desactiver son raisonnement -- seulement en regler la profondeur via HERMES_REASONING_EFFORT (low/medium/high). Sans vision : l'extraction de fichier reste sur qwen2.5vl:7b. Hermes n'a pas de slot nomme raisonnement: le modele principal est celui avec lequel l'agent pense.⁴ OLLAMA_MAX_LOADED_MODELS=1. mem_limit Ollama 18g.

5b. Cartographie as-is / cible v2

Source: Cartographie Blueseatra v2 (16 aout 2026). v1 = console + un LLM pour extraire. v2 ajoute n8n omnicanal, Hermes multi-modeles, et un objet canonique unique. Facturation carte hors v2 initiale.

Couche	As-is	Cible v2
Entree	Upload / collage UI	n8n: sites, IMAP, Drive, CRM, WhatsApp
Normalisation	FastAPI requests.extracted	Objet canonique n8n avant l'IA
IA	Un appel Ollama	Extracteur 14B, redacteur 27B, raisonneur Gemma
Calcul	matching.py deterministe	Inchange
Sortie	Editeur + PDF	Idem + email / CRM / Slack / ERP

Objet canonique (aucun connecteur ne parle au moteur dans son format natif): tenant_id, source_type (webform|email|crm|whatsapp|drive|erp|ui), source_ref, contact_*, message_text, attachments, site_address, requested_service, urgency, thread_id, received_at. Statuts anti-rejeu: recu, analyse, a valider, devis genere.

Moteur devis: types material, labor, travel, note, page_break, lot, subplot. Lots TCE auto: Gros oeuvre, Platerie, Electricite, Plomberie, CVC, Sols, Peinture, Serrurerie, Maintenance. Baremes skill: spot 0,45 h/u, ballon ECS 4,5 h, min visite 2 h, +1,25 h install/repli, max 7 h/j, MO arrondie a l'heure superieure. Defaut 42 EUR HT/h, 40 EUR HT/jour IDF, fournitures x 1,40.

5c. Pack n8n P1

Source: Guide import n8n P1. Workflows inactifs, aucun secret inclus. Import un fichier a la fois (menu n8n Import from File).

Fichier	Role
WF-normalize-ai-quote.json	Hub Normalize then AI then Quote
WF-web-webhook.json	Sites clients
WF-email-imap.json	IMAP generique
WF-email-zoho.json	Zoho Mail imap.zoho.com:993
WF-email-gmail.json	Gmail

Fichier	Role
WF-email-outlook.json	Outlook 365

Credentials: Blueseatra JWT (Authorization Bearer d'un owner), boite mail par tenant. Remplacer `REPLACER_TENANT_ID`. Activer le hub d'abord, puis un canal test. Hub: <https://n8n.blueseatra.com/webhook/blueseatra-normalize> Site: <https://n8n.blueseatra.com/webhook/blueseatra-intake> Le pack ne calcule pas de prix, n'active pas Drive/CRM/WhatsApp (P2+).

6. Modele de donnees

14 tables PostgreSQL, cles UUID, champs dynamiques en JSONB. Filtrage systematique par `tenant_id`.

Table	Role
users / tenants / tenant_users	Comptes, espaces, roles
catalogs / catalog_versions / pricing_items	Catalogue versionne, attributs dynamiques
requests	Demandes + extraction JSONB
quotes / quote_versions	Devis, lignes, snapshot tarifaire
import_jobs / import_errors	Imports CSV
audit_logs	Journal
settings_integrations / company_profiles	IA, n8n, mentions PDF

7. Variables d'environnement

Backend Render (secrets hors Git):

Variable	Usage
DATABASE_URL	Pooler Supabase :6543
JWT_SECRET / APP_ENCRYPTION_KEY	Auth et secrets au repos
HERMES_BASE_URL	https://ia.blueseatra.com
HERMES_API_KEY	X-API-Key = OLLAMA_API_KEY VPS
HERMES_EXTRACT_MODEL	qwen2.5:7b
HERMES_REASONING_MODEL	gpt-oss:20b
HERMES_REASONING_EFFORT	medium (low/medium/high)
HERMES_GATEWAY_URL	https://hermes.blueseatra.com
HERMES_GATEWAY_KEY	API_SERVER_KEY du VPS (Bearer)
MCP_API_KEY / MCP_TENANT_ID	Connecteur lecture seule
DB_SCHEMA	blueseatra (attention: render.yaml historique public)

VPS ovh-ai-stack: OLLAMA_API_KEY, API_SERVER_KEY, HERMES_MODEL=gpt-oss:20b. Ne jamais coller les cles dans le chat.

8. Securite

- JWT fort, bcrypt, role relu en base (pas depuis le token seul).
- Isolation tenant + 404 inter-espaces.

- Cles IA tenant chiffrées Fernet.
- CORS origines explicites. Upload 15 Mo.
- Caddy: TLS, X-API-Key, aucun port modèle exposé.
- API Hermes: Bearer distinct, max_concurrent_runs=1, pas de publication 8642.
- RLS deny-all côté PostgREST public.

9. Mode d'emploi

- Créer un espace (/signup).
- Importer le catalogue CSV (mapping colonnes, activer une version).
- Créer une demande (texte ou fichier). L'IA extrait.
- Générer un brouillon. Vérifier les lignes, lots, TVA.
- Ajouter depuis le catalogue si besoin (brouillon uniquement).
- Renseigner le profil société. Valider. Télécharger le PDF.



Le catalogue reste la seule source de prix.

10. API (extrait)

Methode	Route	Role
POST	/api/auth/login	Connexion
POST	/api/requests	Nouvelle demande
POST	/api/requests/{id}/process	Relancer l'extraction
POST	/api/quotes/draft	Brouillon depuis une demande
GET	/api/catalog/search	Picker catalogue
GET	/api/quotes/{id}/pdf	PDF Pro Forma
POST	/mcp	Outils lecture seule Perplexity

11. Frontend

Routes: / landing publique, /login /signup, /app tableau de bord, demandes, catalogues, devis, membres, audit, parametres. Logo dans public/brand/. Landing refondue (PR 26): parcours, temps gagne, fonctions, photos.



Identite: navy #193852, teal #438C88, papier #F7F4EE.

12. Deploiement

- Frontend: git pull && yarn build puis upload Hostinger du dossier build.
- Backend: Render auto-deploy depuis main (region Francfort).
- IA: git pull sur le VPS (cle github_ovh_ai_stack) puis docker compose up -d --force-recreate hermes.
- DNS A: ia / n8n / hermes.blueseatra.com → 162.19.44.2.

13. Journal aout 2026

Date	Livable
15-16 aout	Stack OVH, qwen3.6:27b, cartographie v2
17 aout	gemma4:26b installe, ADR-003, API Hermes ADR-004
17 aout	PR 22: extract 14B / reason Gemma via gateway
17 aout	Test devis BS-2026-0017 (ballon ECS)
17 aout	Logo + landing (PR 24, 25, 26)
23 aout	Suppression de 6 modeles VPS (63 Go), repointage extract/vision
23 aout	PR 47: X-Hermes-Session-Id (ADR-005 ovh-ai-stack)
23 aout	PR 48: gpt-oss:20b modele de raisonnement ; PR 49: niveau gradue

14. Sources

1. Ollama gemma4:26b: <https://ollama.com/library/gemma4:26b>
2. Gemma + Ollama: <https://ai.google.dev/gemma/docs/integrations/ollama>
3. Hermes API server: <https://hermes-agent.nousresearch.com/docs/user-guide/features/api-server>
4. Hermes Docker: <https://hermes-agent.nousresearch.com/docs/user-guide/docker>
5. Hermes configuring models: <https://hermes-agent.nousresearch.com/docs/user-guide/configuring-models>